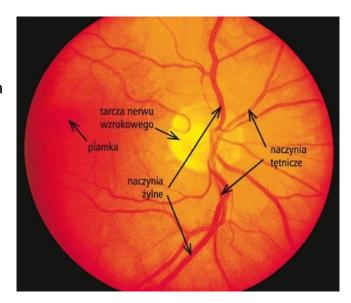
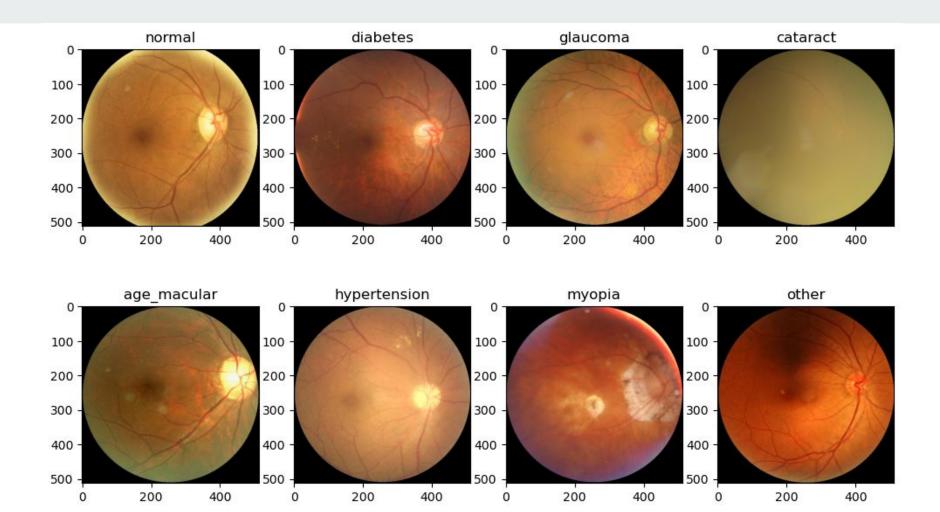
## Ocular disease recognition

Jakub Szpunar

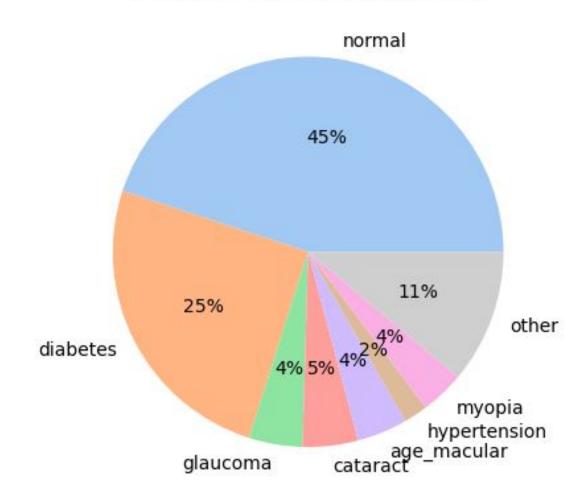
## **Temat**

Klasyfikacja wieloklasowa chorób oczu na podstawie zdjęć dna oka przy pomocy konwolucyjnej sieci neuronowej.





#### Ocular Disease data distribution



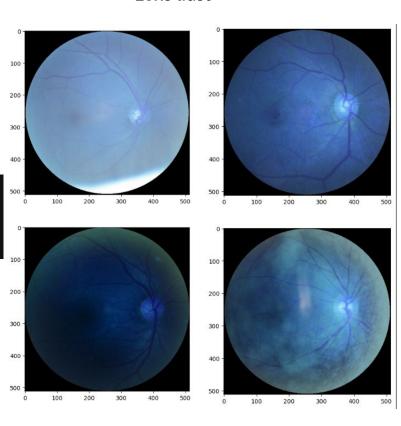
## **Preprocessing danych**

```
'hypertensive retinopathy, age-related macular degeneration',
'epiretinal membrane, moderate non proliferative retinopathy, laser spot',
'vitreous degeneration, lens dust', 'low image quality, maculopathy',
'moderate non proliferative retinopathy, lens dust, drusen',
'mild nonproliferative retinopathy, lens dust, drusen',
'wet age-related macular degeneration, myopia retinopathy',
'macular epiretinal membrane, laser spot',
'epiretinal membrane, epiretinal membrane, lens dust',
```

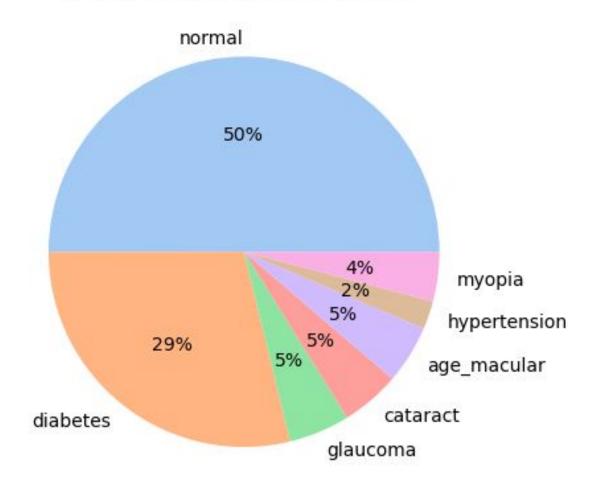
```
'mild nonproliferative retinopathy, vitreous degeneration',
'vitreous degeneration, mild nonproliferative retinopathy',
'optic disk photographically invisible',
'moderate non proliferative retinopathy, chorioretinal atrophy',
'epiretinal membrane over the macula, white vessel',
'laser spot, white vessel',
```

Pozbycie się problematycznych zdjęć oraz klasy 'other' + resize z 512x512 do 256x256

#### Lens dust



#### Ocular Disease data distribution



#### Pierwszy prosty model

```
[21]: model1 = models.Sequential()
  model1.add(layers.Conv2D(32, (3, 3), activation='relu', input_shape=(img_rows, img_cols, 3)))
  model1.add(layers.MaxPooling2D((2, 2)))
  model1.add(layers.Conv2D(64, (3, 3), activation='relu'))
  model1.add(layers.MaxPooling2D((2, 2)))
  model1.add(layers.Conv2D(128, (3, 3), activation='relu'))
  model1.add(layers.MaxPooling2D((2, 2)))
  model1.add(layers.Flatten())
  model1.add(layers.Dense(64, activation='relu'))
  model1.add(layers.Dense(num_class, activation='softmax'))
```

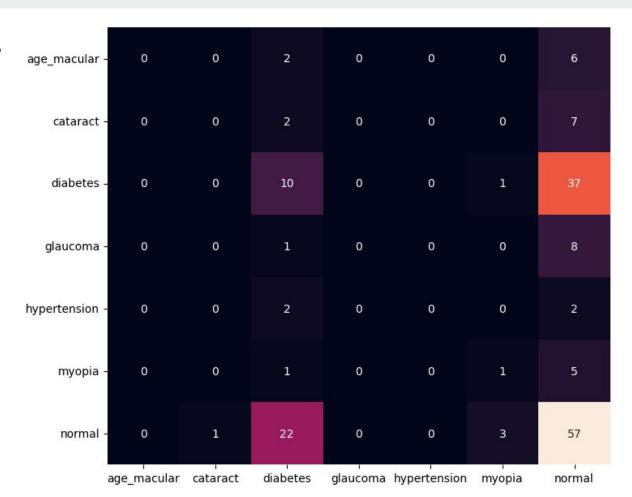
Accuracy jako metryka przy niezbalansowanym datasecie nie jest dobrym wyborem. Lepszym wyborem jest Recall, Precision lub F1

Accuracy prawie ~48% przy 8 klasach nie jest najgorszym wynikiem dla tak prostego modelu biorąc pod uwagę użyty dataset, lecz trzeba zauważyć, że aż 50% stanowią obrazy klasy 'normal'.

### Użycie bardziej rozbudowanego modelu

```
model8 = models.Sequential()
•[34]:
       model8.add(layers.Conv2D(64, (3, 3), activation='relu', input shape=(img rows, img cols, 3)))
       model8.add(layers.MaxPooling2D((2, 2), padding='same'))
       model8.add(layers.Conv2D(128, (3, 3), activation='relu'))
       model8.add(layers.Conv2D(256, (3, 3), activation='relu'))
       model8.add(layers.MaxPooling2D((2, 2), padding='same'))
       model8.add(layers.Conv2D(512, (3, 3), activation='relu'))
       model8.add(layers.Conv2D(256, (3, 3), activation='relu'))
       model8.add(layers.MaxPooling2D((2, 2), padding='same'))
       model8.add(layers.Flatten())
       model8.add(layers.Dropout(0.5))
       model8.add(layers.Dense(256, activation='relu'))
       model8.add(layers.Dense(7, activation='softmax'))
       model8.compile(loss=tf.keras.losses.CategoricalCrossentropy().
                     optimizer=tf.keras.optimizers.Adam(),
                     metrics=[tf.keras.metrics.Recall(), tf.keras.metrics.Precision()])
```

#### **Rezultat**



- 50

- 40

- 30

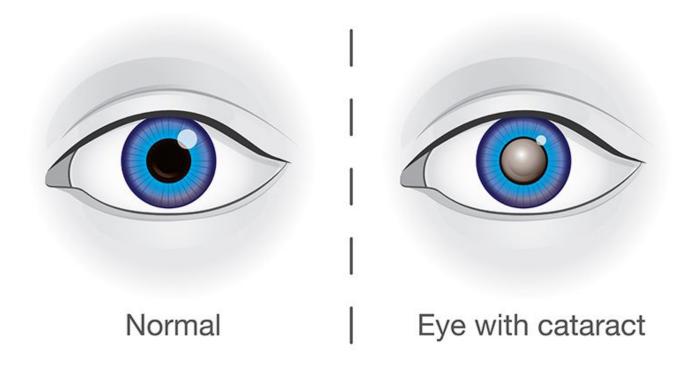
- 20

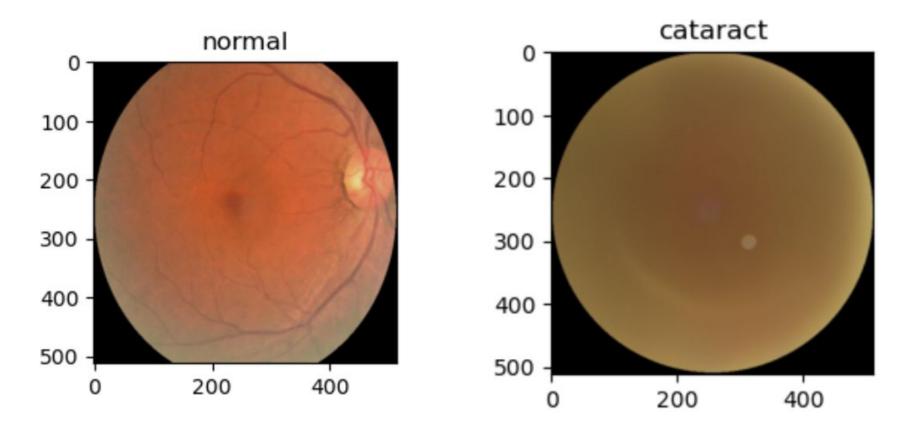
- 10

## Test na zbiorze walidacyjnym



#### Ograniczenie liczby klas - sprawdzenie jak modele radzą sobie z klasyfikacją binarną



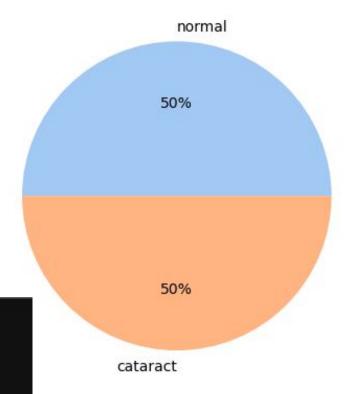


## Ograniczenie zbioru - równa liczebność klas

['normal', 'cataract']
[269, 269]

Found 376 images belonging to 2 classes.
Found 50 images belonging to 2 classes.
Found 112 images belonging to 2 classes.

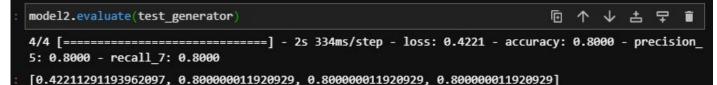
Ocular Disease data distribution



#### Model

```
model2 = models.Sequential()
[339]:
       model2.add(layers.Conv2D(64, (3, 3), activation='relu', input shape=(img rows, img cols, 3)))
       model2.add(layers.MaxPooling2D((2, 2), padding='same'))
       model2.add(layers.MaxPooling2D((2, 2), padding='same'))
       model2.add(layers.Conv2D(128, (3, 3), activation='relu'))
       model2.add(layers.Conv2D(256, (3, 3), activation='relu'))
       model2.add(layers.MaxPooling2D((2, 2), padding='same'))
       model2.add(layers.MaxPooling2D((2, 2), padding='same'))
       model2.add(layers.Conv2D(512, (3, 3), activation='relu'))
       model2.add(layers.Conv2D(256, (3, 3), activation='relu'))
       model2.add(layers.MaxPooling2D((2, 2), padding='same'))
       model2.add(layers.MaxPooling2D((2, 2), padding='same'))
       model2.add(lavers.Flatten())
       model2.add(layers.Dropout(0.5))
       model2.add(layers.Dense(256, activation='relu'))
       model2.add(layers.Dense(1, activation='sigmoid'))
       model2.summary()
```

Precision vs Validation Precision 0.9 0.8 0.7 0.6 0.5 10 12 14 Recall vs Validation Recall 1.0 0.8 0.6 0.4 10 12 14 F1 vs Validation F1 0.8 0.7 0.6 0.5 10 12 14 8



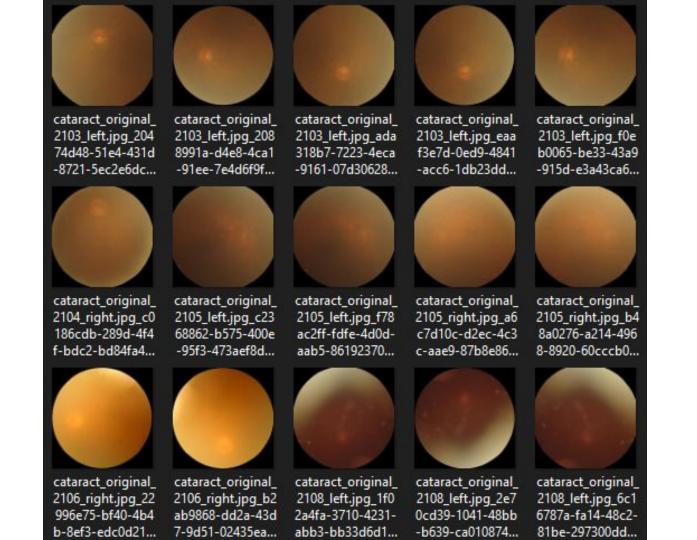
validation

train

Acc = 80%

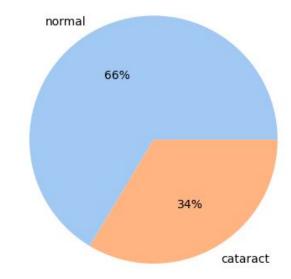
## Augment fundus images

```
import Augmentor
 [2]:
 [9]: img dir path1 = "./dataset256 multi/train/cataract"
      img dir path2 = "./dataset256 multi/train/myopia"
      img dir path3 = "./dataset256 multi/train/age macular"
      p = Augmentor.Pipeline(img dir path3)
      Initialised with 186 image(s) found.
      Output directory set to ./dataset256 multi/train/age macular\output.
[10]: p.rotate(probability=1, max left rotation=7, max right rotation=7)
      p.flip left right(probability=0.7)
      p.flip top bottom(probability=0.7)
      p.rotate random 90(probability=0.7)
      p.zoom(probability=0.5, min factor=0.9, max factor=1.1)
[11]: p.sample(186*4)
      Processing <PIL.Image.Image image mode=RGB size=256x256 at 0x207E9FCCC40>: 100%
                                                                                                  744/744 [00:02
      <00:00, 291.77 Samples/s]
```

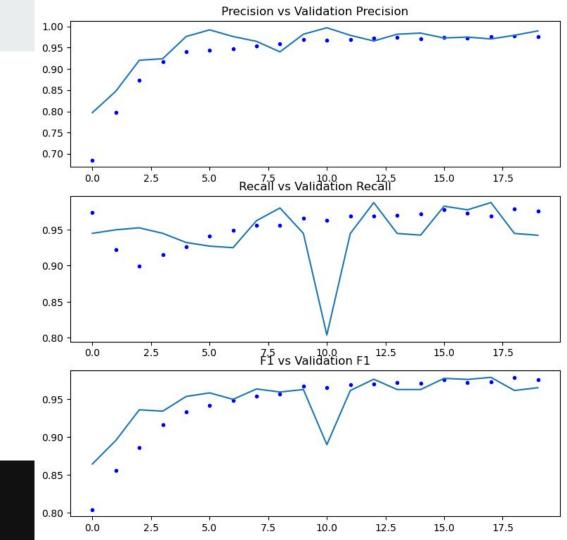


## Wyniki po augmentacji

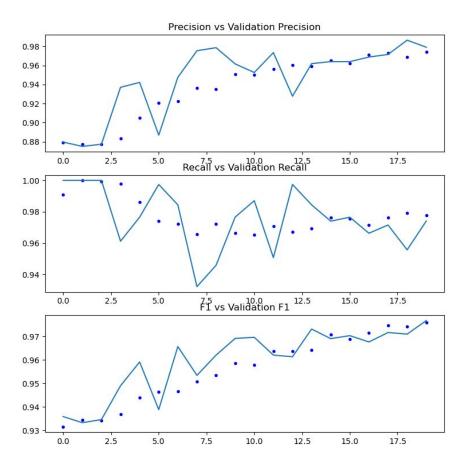
Ocular Disease data distribution



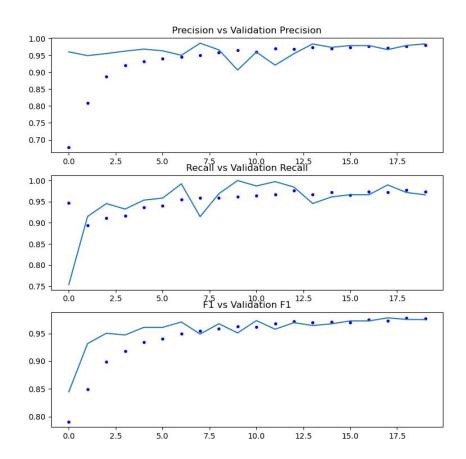
Found 2019 images belonging to 2 classes. Found 261 images belonging to 2 classes. Found 605 images belonging to 2 classes.



#### Bez augmentacji (269 'cataract', 2000 'normal')

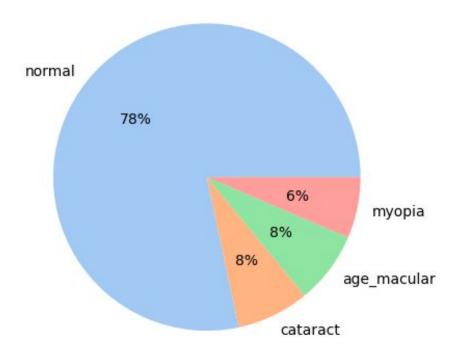


#### Po augmentacji(800 'cataract', 2000 'normal')



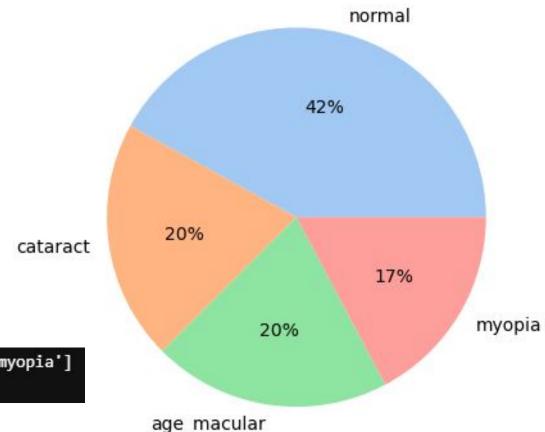
## Powrót do klasyfikacji wieloklasowej

Ocular Disease data distribution



Ocular Disease train set after augmentation

Zbiór walidacyjny i testowy nie zawierają danych augmentowanych.

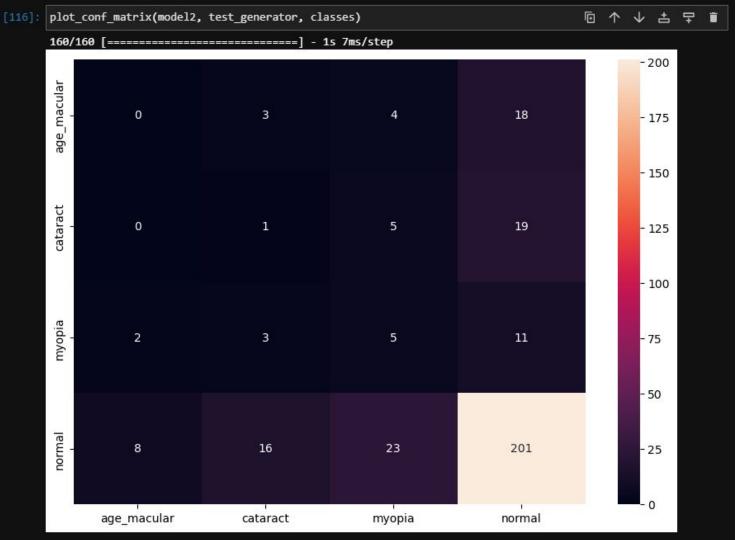


['normal', 'cataract', 'age\_macular', 'myopia'] [1926, 940, 930, 790]

```
model2 = models.Sequential()
model2.add(layers.Conv2D(512, (3, 3), activation='relu', input_shape=(img_rows, img_cols, 3)))
model2.add(layers.MaxPooling2D((2, 2), padding='same'))
model2.add(layers.MaxPooling2D((2, 2), padding='same'))
model2.add(layers.Conv2D(512, (3, 3), activation='relu'))
model2.add(layers.Conv2D(512, (3, 3), activation='relu'))
model2.add(layers.MaxPooling2D((2, 2), padding='same'))
model2.add(layers.Conv2D(256, (3, 3), activation='relu'))
model2.add(layers.MaxPooling2D((2, 2), padding='same'))
model2.add(layers.Conv2D(256, (3, 3), activation='relu'))
model2.add(layers.Flatten())
model2.add(layers.Dense(256, activation='relu'))
model2.add(layers.Dense(class_num, activation='softmax'))
```

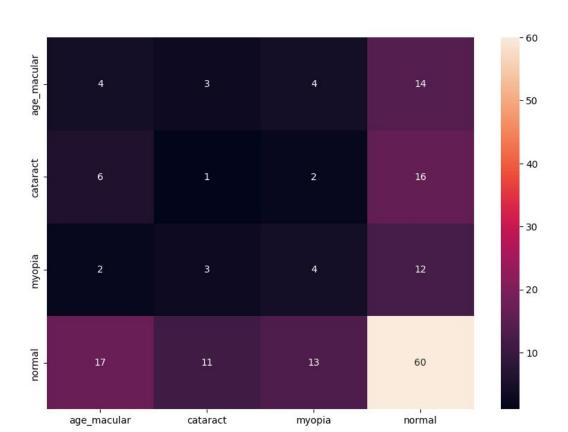
model2.summary()

Model: "sequential 14"



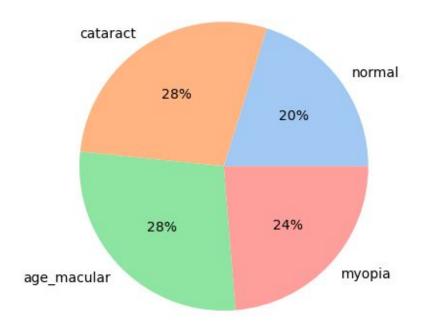


## Brak większych rezultatów dla zbioru testowego



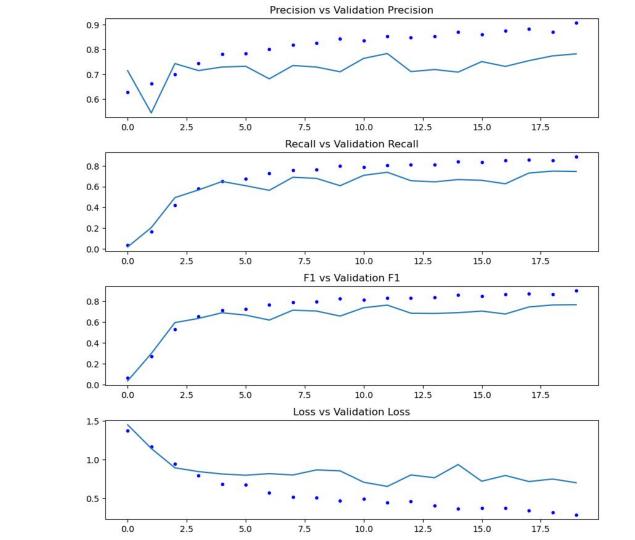
# Zmniejszenie ilości zdjęć klasy 'normal' w zbiorze treningowym (undersampling)

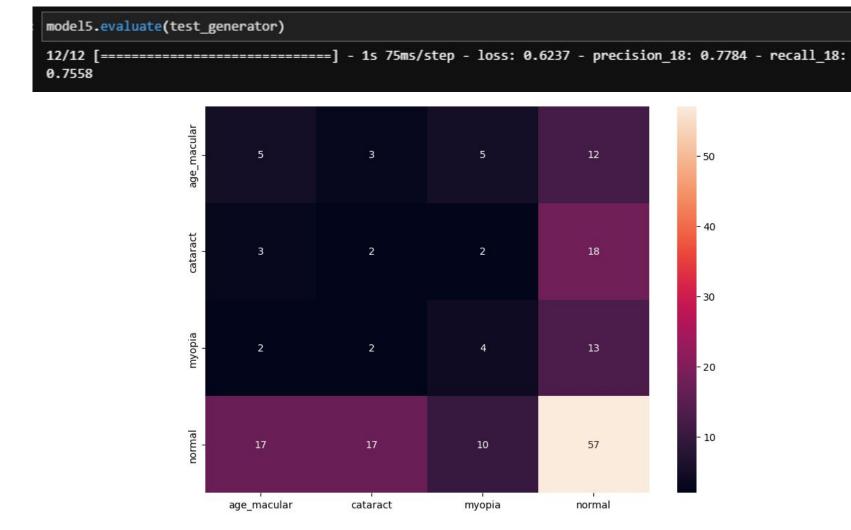
Ocular Disease train set after augmentation



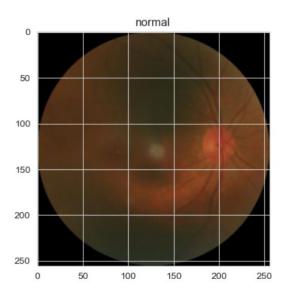
## Kolejny model

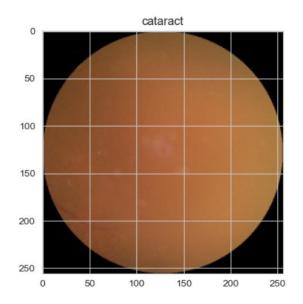
```
model5 = models.Sequential()
model5.add(layers.Conv2D(64, (3, 3), activation='relu', input shape=(img rows, img cols, 3)))
model5.add(layers.MaxPooling2D((2, 2), padding='same'))
model5.add(layers.Conv2D(256, (3, 3), activation='relu'))
model5.add(layers.MaxPooling2D((2, 2), padding='same'))
model5.add(layers.Conv2D(512, (3, 3), activation='relu'))
model5.add(layers.MaxPooling2D((2, 2), padding='same'))
model5.add(layers.Conv2D(256, (3, 3), activation='relu'))
model5.add(layers.MaxPooling2D((2, 2), padding='same'))
model5.add(layers.Conv2D(256, (3, 3), activation='relu'))
model5.add(layers.MaxPooling2D((2, 2), padding='same'))
model5.add(layers.Conv2D(128, (3, 3), activation='relu'))
model5.add(layers.MaxPooling2D((2, 2), padding='same'))
model5.add(layers.Flatten())
model5.add(layers.Dense(128, activation='relu'))
model5.add(layers.Dense(class num, activation='softmax'))
model5.summary()
```

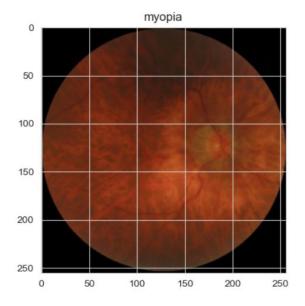


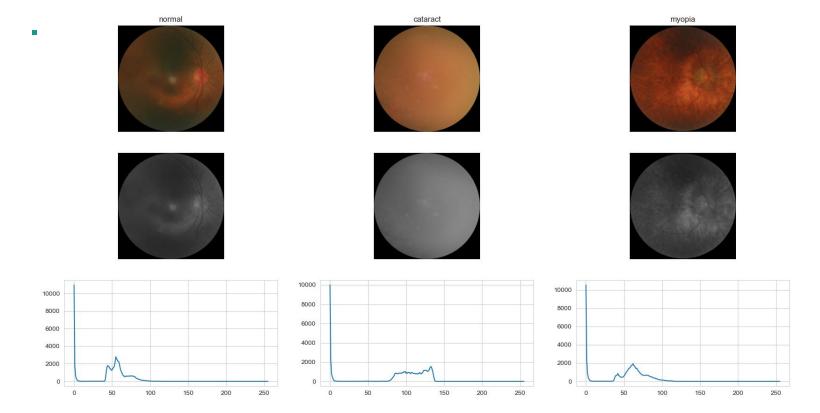


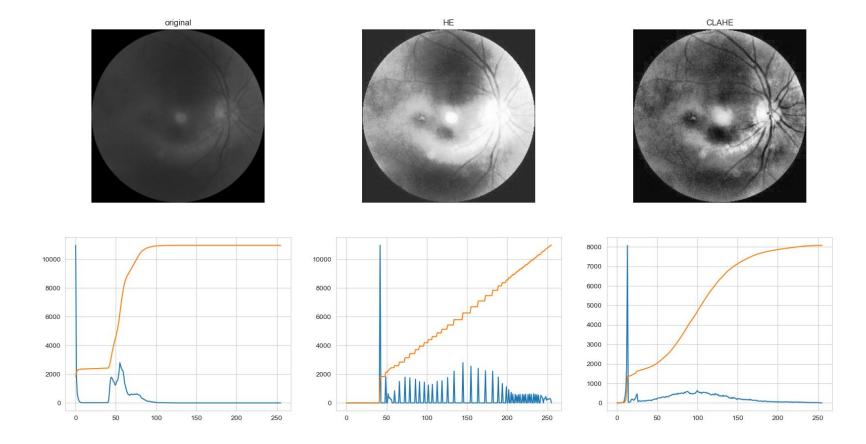
#### Przetwarzanie obrazów

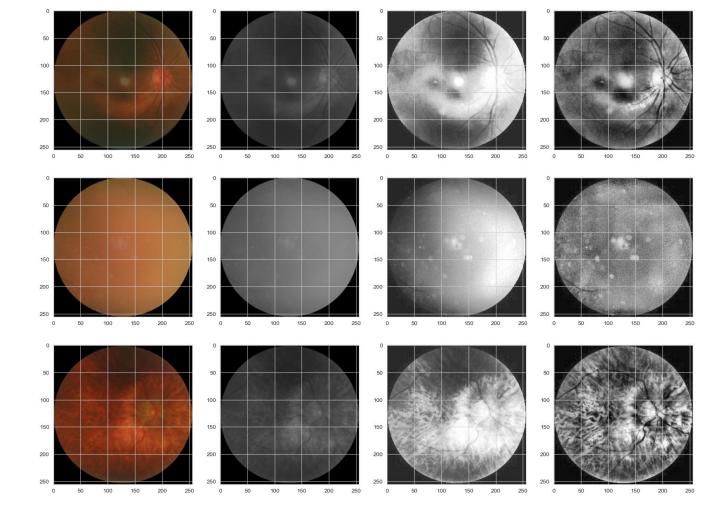












#### Model

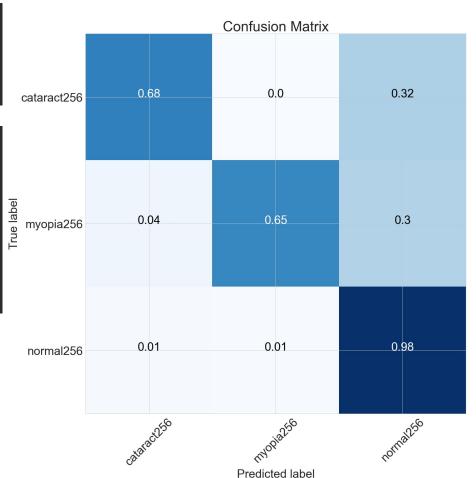
```
model = models.Sequential()
  model.add(layers.Conv2D(32, (3, 3), activation='relu', input_shape=(img_rows, img_cols, 1)))
  model.add(layers.MaxPooling2D((2, 2)))
  model.add(layers.Conv2D(64, (3, 3), activation='relu')),
  model.add(layers.MaxPooling2D((2, 2)))
  model.add(layers.Conv2D(128, (3, 3), activation='relu'))
  model.add(layers.MaxPooling2D((2, 2)))
  model.add(layers.Flatten())
  model.add(layers.Dense(64, activation='relu'))
  model.add(layers.Dense(3, activation='softmax'))
model1.compile(loss=tf.keras.losses.CategoricalCrossentropy(),
              optimizer = tf.keras.optimizers.Adam(),
              metrics = [tf.keras.metrics.Precision(), tf.keras.metrics.Recall(), 'accuracy'])
```

SET 0 - without oversampling Found 2272 images belonging to 3 classes. Found 327 images belonging to 3 classes. Found 648 images belonging to 3 classes.

lassificatio	n Report			
	precision	recall	f1-score	support
cataract256	0.83	0.68	0.75	28
myopia256	0.88	0.65	0.75	23
normal256	0.94	0.98	0.96	276
accuracy			0.93	327
macro avg	0.88	0.77	0.82	327
weighted avg	0.93	0.93	0.93	327

#### Test / Train set:

- 276 / 1926 normal
- 28 / 188 cataract
- 23 / 158 myopia



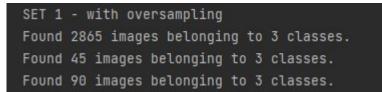
0.8

0.6

0.4

0.2

0.0



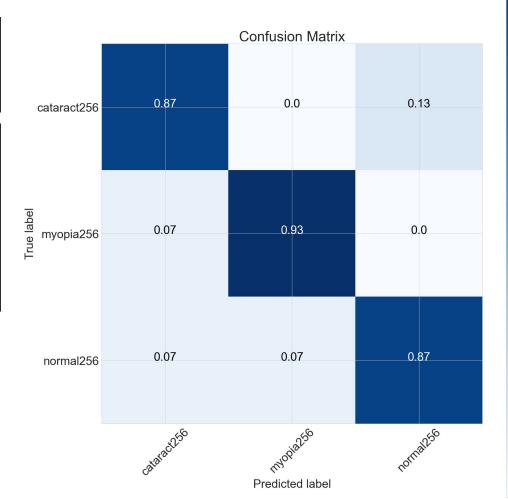
		0.000	Sea Common	
	precision	recall	f1-score	support
cataract256	0.87	0.87	0.87	15
myopia256	0.93	0.93	0.93	15
normal256 accuracy		0.87	0.87	15
		0.89	45	
macro avg	0.89	0.89	0.89	45
weighted avg	0.89	0.89	0.89	45



• 955 images each class

#### Test set:

- 15 normal
- 15 cataract
- 15 myopia



0.8

0.6

0.4

-0.2

### Model 2

```
model = models.Sequential()
 model.add(layers.Conv2D(64, (3, 3), activation='relu', input_shape=(img_rows, img_cols, 1)))
 model.add(layers.MaxPooling2D((2, 2)))
 model.add(layers.Conv2D(128, (3, 3), activation='relu'))
 model.add(layers.MaxPooling2D((2, 2)))
 model.add(layers.Conv2D(256, (3, 3), activation='relu'))
 model.add(layers.MaxPooling2D((2, 2)))
 model.add(layers.Conv2D(512, (3, 3), activation='relu'))
 model.add(layers.MaxPooling2D((2, 2)))
 model.add(layers.Conv2D(256, (3, 3), activation='relu'))
 model.add(layers.MaxPooling2D((2, 2)))
 model.add(layers.Flatten())
 model.add(layers.Dropout(0.5))
 model.add(layers.Dense(256, activation='relu'))
 model.add(layers.Dense(3, activation='softmax'))
model3.compile(loss=tf.keras.losses.CategoricalCrossentropy(),
              optimizer = tf.keras.optimizers.Adam(),
              metrics = [tf.keras.metrics.Precision(), tf.keras.metrics.Recall(), 'accuracy'])
```

SET 1 - with oversampling Found 2865 images belonging to 3 classes. Found 45 images belonging to 3 classes. Found 90 images belonging to 3 classes.

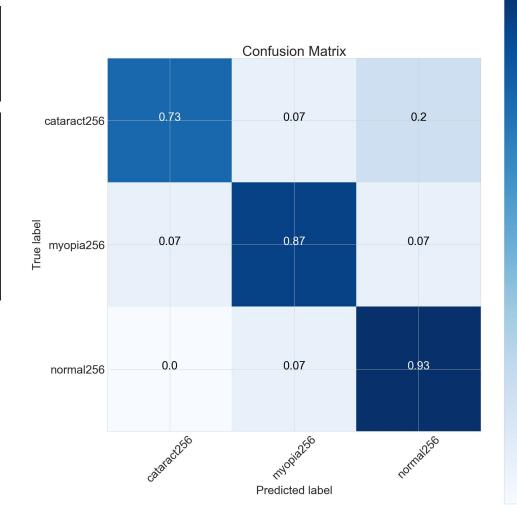
Classificatio	n Report			
	precision	recall	f1-score	support
cataract256	0.87	0.87	0.87	15
myopia256	0.93	0.93	0.93	15
normal256	0.87	0.87	0.87	15
accuracy			0.89	45
macro avg	0.89	0.89	0.89	45
weighted avg	0.89	0.89	0.89	45

#### Train:

• 955 images each class

#### Test set:

- 15 normal
- 15 cataract
- 15 myopia



0.8

0.6

0.4

0.2

SET 2 - with oversampling and increased images in test & validation sets
Found 2760 images belonging to 3 classes.
Found 120 images belonging to 3 classes.
Found 120 images belonging to 3 classes.

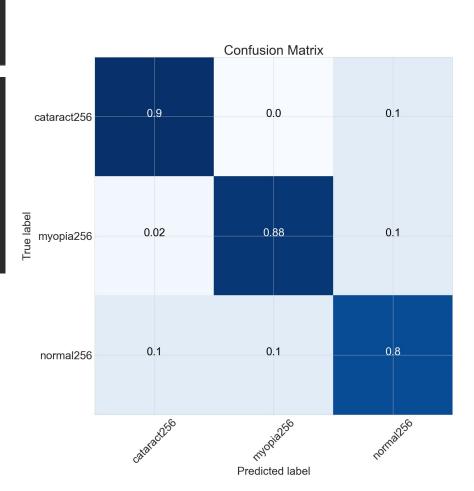
Classification Report						
		precision	recall	f1-score	support	
	1.0					
	cataract256	0.88	0.90	0.89	40	
	myopia256	0.90	0.88	0.89	40	
	normal256	0.80	0.80	0.80	40	
	accuracy			0.86	120	
	macro avg	0.86	0.86	0.86	120	
	weighted avg	0.86	0.86	0.86	120	

#### Train:

• 920 images each class

#### Test set:

- 40 normal
- 40 cataract
- 40 myopia



0.9

0.8

0.7

0.6

0.5

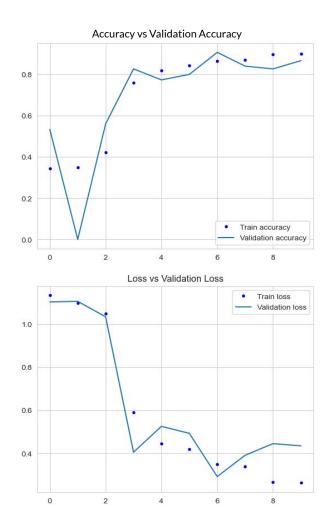
0.4

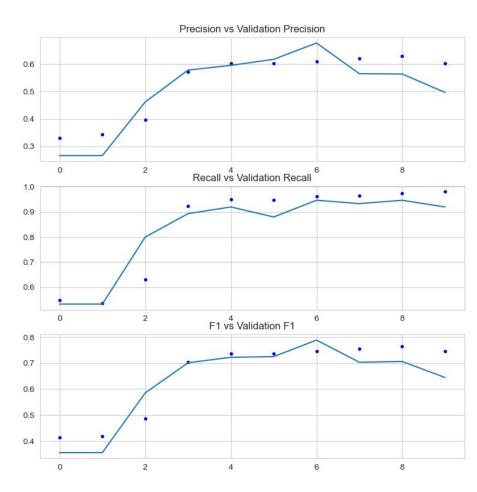
0.3

-0.2

0.1

0.0





### Porównanie z RGB

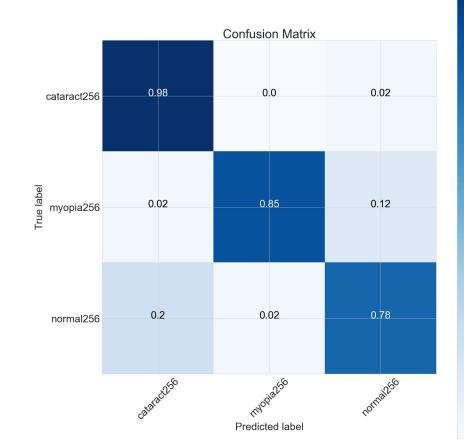
#### Train:

• 920 images each class

#### Test set:

- 40 normal
- 40 cataract
- 40 myopia

			ra	
	precision	recall	f1-score	support
cataract256	0.81	0.97	0.89	40
myopia256	0.97	0.85	0.91	40
normal256	0.84	0.78	0.81	40
accuracy			0.87	120
macro avg	0.87	0.87	0.87	120
weighted avg	0.87	0.87	0.87	120



0.8

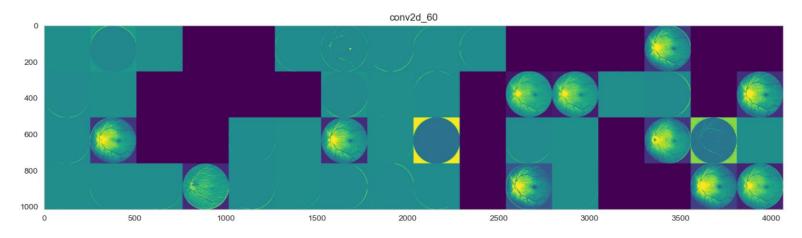
0.6

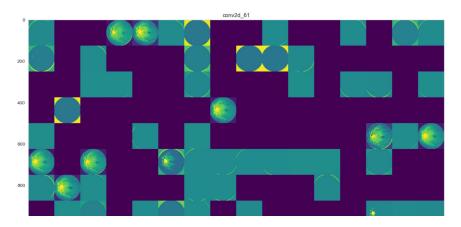
0.4

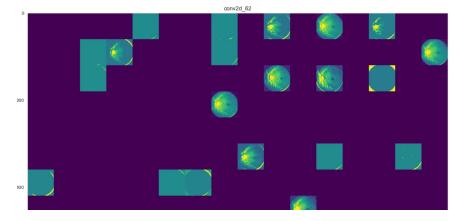
0.2

0.0

## Filtry modelu

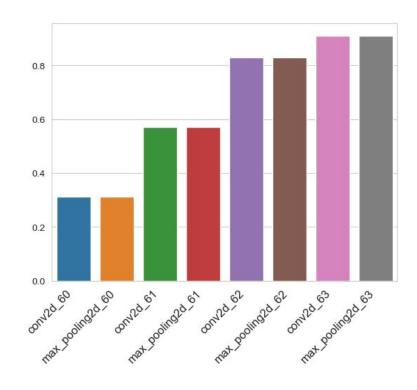






### Filtry martwe

Potencjalnych filtrów martwych jest całkiem sporo, lecz aby potwierdzić, że filtry wykazujące brak wzorca są martwe potrzebne by było sprawdzenie czy sytuacja powtarza się nie dla jednego zdjęcia, a dla wielu, najlepiej różnorodnych zdjęć.



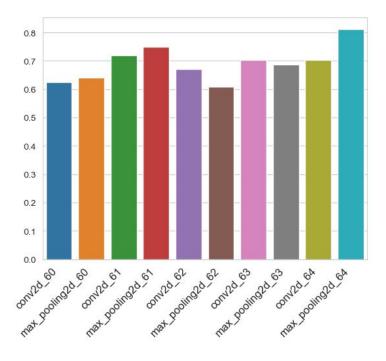
Procentowy udział potencjalnych filtrów martwych dla każdej z warstw

### Występowanie szumu losowego



Ilość filtrów zawierających szum losowy w zbudowanym modelu jest na zaskakująco wysokim poziomie.

Kolejnymi krokami, które mogłyby pomóc w redukcji tak wielu filtrów szumu mogłaby być analiza zachowania sieci przy zastosowaniu różnych funkcji aktywacji w warstwach, lecz ograniczenia czasowe nie pozwoliły na sprawdzenie tego na ten moment.



Procentowy udział filtrów reprezentujących szum losowy dla każdej z warstw

### **Podsumowanie**

Podczas projektu największym problemem była nierówny rozkład zdjęć pomiędzy klasy chorób oczu oraz różna jasność niezależnie od klasy do której zdjęcia należą.

Po kilku próbach uczenia na wszystkich klasach po paśmie porażek postanowiłem zacząć od klasyfikacji binarnej, która poszła o wiele lepiej.

Finalnie udało się dokonać stosunkowo dobrej klasyfikacji wieloklasowej dla klas myopia, normal, cataract.

Oczywiście sam model można poprawić na co wskazuje duża ilość filtrów szumu w ConvNet, lecz niestety z powodu intensywnej końcówki semestru zabrakło na to czasu.

### Podsumowanie cd.

Na zajęciach pogłębiłem swoją wiedzę z zakresu obróbki danych do uczenia, tworzenia różnych architektur sieci neuronowych (głównie CNN) wraz z walidacją i analizą procesu ich uczenia.

Dodatkowo, zajęcia z pewnością pozwoliły rozeznać się jak szerokie i często wymagające są zagadnienia związane z sieciami neuronowymi. Z pewnością w najbliższym czasie skupię się bardziej na tych zagadnieniach, aby bardziej świadomie budować sieci i przy ich użyciu rozwiązywać coraz bardziej złożone problemy.

Sieci neuronowe jak i sztuczna inteligencja są bardzo ciekawym narzędziem, które pozwala na rozwiązanie wielu nietrywialnych problemów, a i ich użycie staje się coraz bardziej powszechne, co także motywuje do działania i zgłębiania informacji w tym zakresie.

# The end